

Aprendizaje Automático para la Identificación de Riesgo en Adolescentes Salvadoreños: Análisis del GSHS 2013

David Deras

Facultad de Ingeniería y Arquitectura
Universidad de El Salvador
San Salvador, El Salvador
dc19019@ues.edu.sv

Resumen—Este artículo presenta el diseño, implementación y evaluación de un sistema de aprendizaje automático para identificar los principales factores predictores de riesgo en adolescentes salvadoreños, utilizando los datos del Global School-based Student Health Survey (GSHS) 2013 de la Organización Mundial de la Salud [1]. El sistema comprende dos modelos: uno de regresión para predecir el Índice de Masa Corporal (IMC) a partir de hábitos de vida autorreportados, y uno de clasificación binaria para identificar riesgo de salud mental (suicidalidad). Los resultados muestran que el modelo de regresión del IMC no logró capacidad predictiva útil ($R^2 \approx 0$), confirmando que el comportamiento autorreportado es insuficiente para inferir el IMC. En contraste, el clasificador de riesgo de salud mental basado en regresión logística con hiperparámetros optimizados mediante GridSearchCV obtuvo un AUC-ROC de 0.81 y un recall de 0.62 sobre la clase en riesgo, con los síntomas afectivos (soledad e insomnio) como predictores más relevantes. Se discuten las implicaciones para la política pública y se propone un esquema de tamizaje escolar escalable para El Salvador.

Index Terms—aprendizaje automático, salud adolescente, riesgo de salud mental, GSHS, El Salvador, clasificación binaria, política pública

I. INTRODUCCIÓN

La salud de los adolescentes representa uno de los desafíos más urgentes para los sistemas de salud de países en desarrollo. En El Salvador, los jóvenes de entre 13 y 17 años enfrentan exposición temprana a factores de riesgo conductuales —consumo de sustancias, violencia escolar, sedentarismo— que se asocian con consecuencias graves en la salud adulta. La detección temprana de estos riesgos es una prioridad de la agenda de salud pública.

La Organización Mundial de la Salud desarrolló el Global School-based Student Health Survey (GSHS) precisamente para medir estos factores de riesgo a escala poblacional [1]. Los datos del GSHS 2013 para El Salvador constituyen la fuente pública más reciente disponible para el país y ofrecen una oportunidad única para construir modelos predictivos que apoyen la toma de decisiones en políticas de salud.

Este artículo propone un sistema de aprendizaje automático que opera sobre dichos datos con dos objetivos diferenciados: (1) predecir el Índice de Masa Corporal (IMC) a partir de hábitos de alimentación y actividad física, y (2) identificar

estudiantes con riesgo de salud mental —específicamente suicidalidad— a partir de factores psicosociales y conductuales. El sistema no está diseñado como herramienta de diagnóstico clínico individual, sino como instrumento de vigilancia epidemiológica que permita priorizar la intervención en grupos de riesgo.

II. DESCRIPCIÓN DEL DATASET

II-A. El GSHS 2013 de El Salvador

El GSHS es una encuesta estandarizada desarrollada por la OMS que mide factores de riesgo conductuales y factores de protección en diez áreas clave entre estudiantes de 13 a 17 años [1]. La edición 2013 para El Salvador recopiló 52 preguntas (identificadas como Q1-Q58, omitiendo Q28-Q33), codificadas con valores ordinales politómicos (por ejemplo, “Nunca”, “A veces”, “Frecuentemente”).

El dataset incluye tres capas de variables:

1. **Preguntas originales** Q1-Q58: respuestas ordinales que capturan frecuencias, cantidades o categorías.
2. **Variantes dicotómicas** QN: binarizaciones de las preguntas Q, donde el valor 1 indica “Sí” y 2 indica “No”. Cubren los rangos Q6-Q27, Q34-Q40 y Q44-Q58.
3. **Indicadores derivados**: once variables calculadas sobre la encuesta, incluyendo indicadores de obesidad, sobrepeso y actividad física.

En total, el conjunto de datos contiene 104 variables. Un detalle técnico crítico es el uso del valor centinela $1.7976931348623157E+308$ —el máximo representable por un `float64` según IEEE 754 [6]— para marcar respuestas faltantes o no aplicables. Este valor fue reemplazado por NaN antes de cualquier análisis.

II-B. Variables Excluidas

El análisis de valores faltantes reveló que ciertas columnas QN son submuestras condicionales (aplican solo a quienes respondieron afirmativamente a una pregunta previa), presentando más del 65 % de datos ausentes: QN18, QN19, QN21, QN34, QN36, QN37, QN40, QN45, QN47, QN48, qnc1g y qnc2g. Incluir estas variables introduciría más ruido que señal.

II-C. Selección de Familias de Variables por Modelo

Dado que las columnas Q y QN del mismo dominio están casi perfectamente correlacionadas (la QN es una dicotomización de la Q), mezclarlas introduciría colinealidad. Se adoptó la siguiente política:

- **Regresión (IMC)**: variables Q ordinales, ya que la escala ordinal preserva información que la binarización pierde.
- **Clasificación (salud mental)**: variables QN, donde la presencia/ausencia del comportamiento es la señal relevante.

Las variables demográficas Q1 (edad), Q2 (sexo) y Q3 (grado) se utilizaron en ambos modelos.

III. INGENIERÍA DE VARIABLES

III-A. Variable Objetivo: IMC

El IMC se calculó a partir del peso (Q5, en kg) y la estatura (Q4, en metros) con la fórmula estándar $IMC = \frac{\text{peso}}{\text{estatura}^2}$. Estas variables se utilizaron *exclusivamente* para construir el target; incluirlas como predictoras trivializaría la tarea. El objetivo real del modelo es cuantificar cuánto del IMC es explicable a partir del *estilo de vida* autorreportado.

III-B. Variable Objetivo: Riesgo de Salud Mental

El dataset no contiene una columna única de riesgo de salud mental. Se construyó una variable binaria compuesta a partir de tres preguntas de suicidalidad:

$$y_{\text{mental}} = \mathbb{I}[QN24 = 1 \vee QN25 = 1 \vee QN26 = 1] \quad (1)$$

donde QN24 = ideación suicida, QN25 = plan suicida y QN26 = intento de suicidio en los últimos 12 meses. Estas tres variables fueron excluidas del conjunto de predictores para evitar fuga de datos.

IV. METODOLOGÍA

IV-A. Preprocesamiento dentro del Pipeline

Todo el preprocesamiento se encapsuló dentro de un Pipeline de scikit-learn [2] para garantizar que los parámetros (mediana, media, varianza) se recalculen exclusivamente sobre los datos de entrenamiento en cada fold de la validación cruzada, evitando fuga de datos:

- **Variables categóricas** (Q1, Q2, Q3): imputación por moda + One-Hot Encoding con `drop='first'`.
- **Variables ordinales** (resto de Q y QN): imputación por mediana + `StandardScaler`.

IV-B. Modelo de Regresión del IMC

Se compararon dos modelos con validación cruzada de 5 folds:

- **Regresión Lineal**: línea base interpretable.
- **Random Forest Regressor**: ensemble de árboles que captura relaciones no lineales [4].

Métricas de evaluación: MAE (error absoluto medio), RMSE (raíz del error cuadrático medio) y R^2 (coeficiente de determinación). Los hiperparámetros del Random Forest fueron optimizados automáticamente con GridSearchCV integrado en el pipeline de entrenamiento.

IV-C. Modelo de Clasificación de Riesgo de Salud Mental

La clasificación binaria enfrenta un desbalance de clases pronunciado (mayoría sin riesgo detectado). Se combinaron dos estrategias para compensarlo [5]:

1. `class_weight='balanced'`: aumenta la penalización por errores sobre la clase minoritaria.
2. **SMOTE** (*Synthetic Minority Over-sampling Technique*): genera ejemplos sintéticos de la clase minoritaria, aplicado *dentro* del pipeline de `imbalanced-learn` [3] para que opere exclusivamente en los folds de entrenamiento.

Se compararon Regresión Logística y Random Forest Classifier. Las métricas principales fueron el F1 de la clase minoritaria (estudiantes en riesgo), el recall (sensibilidad) y el AUC-ROC, ya que la accuracy es engañosa bajo desbalance de clases. Los hiperparámetros de todos los modelos se optimizaron con GridSearchCV integrado directamente en el pipeline de entrenamiento, de modo que la búsqueda se ejecuta automáticamente en cada ejecución.

IV-D. Análisis de Ablación

Para cuantificar la contribución de cada dominio de variables al desempeño del clasificador, se realizó un análisis de ablación *leave-one-group-out*: se entrenó el modelo eliminando un grupo temático a la vez y se midió la caída del F1 respecto al modelo completo.

V. RESULTADOS

V-A. Modelo de Predicción del IMC

Las métricas sobre el conjunto de prueba se presentan en la Tabla I.

Cuadro I
DESEMPEÑO DE LOS MODELOS DE REGRESIÓN DEL IMC

Modelo	MAE	RMSE	R^2
Regresión Lineal	2.954	3.892	-0.003
Random Forest (tuneado)	3.041	3.944	-0.030

Un R^2 negativo indica que el modelo predice *peor* que usar siempre el IMC promedio de la muestra. El error absoluto medio de ≈ 3 puntos de IMC es elevado considerando que la desviación estándar del IMC en la muestra ronda los 4 puntos. La validación cruzada confirma el resultado: $R^2_{CV} = 0,003 \pm 0,032$ para la regresión lineal. Incluso con tuning de hiperparámetros, el Random Forest no mejora ($R^2 = -0,030$).

Los hábitos de alimentación, actividad física e higiene *autorreportados* no contienen información suficiente para predecir el IMC de un adolescente. El IMC depende fuertemente de factores no capturados en la encuesta: genética, etapa de desarrollo puberal, composición corporal y el sesgo inherente al autorreporte de comportamientos. Desde la perspectiva de política pública, esto implica que los programas de prevención de obesidad no pueden sustituir la medición física directa del peso y la talla por encuestas conductuales.

V-B. Modelo de Clasificación del Riesgo de Salud Mental

Los resultados del clasificador, se presentan en la Tabla II.

Cuadro II
DESEMPEÑO DE LOS MODELOS DE CLASIFICACIÓN DE RIESGO DE SALUD MENTAL

Modelo	Acc.	F1	Recall	AUC
Reg. Logística (tuneada)	0.781	0.536	0.623	0.808
Random Forest (tuneado)	0.823	0.427	0.325	0.806

Aunque el Random Forest alcanza mayor *accuracy* (0.82), lo hace prediciendo bien la clase mayoritaria (sin riesgo) a costa de la clase que importa — su recall sobre la clase en riesgo es apenas 0.325 (solo detecta 1 de cada 3 estudiantes en riesgo). La Regresión Logística es el modelo seleccionado: su recall de 0.623 sobre la clase en riesgo y su AUC-ROC de 0.808 reflejan una capacidad genuina para discriminar entre estudiantes en riesgo y sin riesgo.

La Fig. 1 muestra la matriz de confusión normalizada del modelo logístico. La Fig. 2 presenta la importancia de cada variable según el valor absoluto de los coeficientes del modelo.




Figura 1. Matriz de confusión normalizada — Regresión Logística (riesgo de salud mental).

V-C. Análisis de Ablación: ¿Qué Variables Importan?

La Tabla III presenta los resultados del análisis de ablación *leave-one-group-out* partiendo de un F1 base de 0.498.

Cuadro III
ANÁLISIS DE ABLACIÓN POR GRUPOS DE VARIABLES (F1 CLASE EN RIESGO)

Grupo retirado	F1	Δ vs. base
(ninguno — base)	0.498	—
Afectivo (soledad, insomnio)	0.444	−0.054
Consumo de sustancias	0.479	−0.019
Violencia / bullying	0.495	−0.003
Dieta y nutrición	0.497	−0.001
Demografía (edad, sexo, grado)	0.498	0.000
Actividad física	0.503	+0.005
Apoyo social	0.507	+0.009




Figura 2. Importancia de características — Regresión Logística (riesgo de salud mental).

El grupo **afectivo** —que incluye la frecuencia con que el estudiante se siente solo y la presencia de insomnio por preocupación— es con diferencia el dominio más valioso. Su eliminación produce una caída de 0.054 puntos de F1, más del doble del impacto de cualquier otro grupo. El consumo de sustancias ocupa el segundo lugar ($\Delta = -0.019$). Sorprendentemente, retirar las variables de actividad física o apoyo social *mejora* ligeramente el modelo, lo que sugiere que estos dominios aportan ruido en lugar de señal cuando el objetivo es predecir riesgo suicida.

VI. SISTEMA PROPUESTO Y VALOR PARA LA POLÍTICA PÚBLICA

VI-A. Arquitectura del Sistema de Tamizaje

El sistema propuesto opera en tres etapas:

1. **Recolección:** encuesta escolar anual simplificada (15 preguntas clave del GSHS, priorizando los dominios afectivo y de consumo de sustancias) aplicada en centros educativos públicos.
2. **Clasificación automatizada:** el pipeline entrenado clasifica a cada estudiante como “en riesgo” o “sin riesgo detectado” y genera reportes agregados por departamento y municipio.
3. **Derivación:** los estudiantes clasificados como en riesgo son derivados a un protocolo de evaluación por personal de salud mental, no tratados directamente por el modelo.

Este diseño respeta un principio fundamental: **el modelo es una herramienta de priorización, no un sustituto del diagnóstico clínico.**

VI-B. Capacidad de Detección a Escala

Con un AUC-ROC de 0.808, el clasificador logra una separación significativamente mejor que el azar (0.50). A modo ilustrativo: si El Salvador tiene aproximadamente 350,000 estudiantes en centros públicos de bachillerato, y la prevalencia de suicidalidad en la muestra GSHS es de $\approx 17\%$, el modelo

permitiría enfocar los recursos de tamizaje especializado en el subconjunto de mayor riesgo predecido por el modelo, reduciendo la carga de evaluación clínica completa mientras se logre aumentar la cobertura efectiva.

VII. LIMITACIONES

Las siguientes limitaciones deben ser consideradas antes de implementar el sistema:

- **Antigüedad de los datos:** el dataset data de 2013. Doce años de cambios socioeconómicos, pandemia y transformaciones en el uso de redes sociales pueden haber alterado los patrones de riesgo. La actualización mediante una nueva ronda GSHS es la recomendación más urgente.
- **Sesgo de autorreporte:** los adolescentes pueden subinformar comportamientos estigmatizados (consumo de sustancias, ideación suicida) o sobreenfocar comportamientos deseables (actividad física). Este sesgo afecta directamente a los modelos entrenados sobre estos datos.
- **Cobertura:** la muestra GSHS es escolar. Los adolescentes fuera del sistema educativo —frecuentemente los más vulnerables— no están representados.
- **Modelo de IMC inutilizable:** con $R^2 \leq 0$ incluso después de tuning de hiperparámetros, el componente de regresión del IMC no debe emplearse para ninguna decisión clínica o de política.
- **Tasa de falsos negativos del clasificador:** el recall de 0.623 sobre la clase en riesgo implica que aproximadamente el 38 % de los estudiantes en riesgo no son detectados. Esta tasa es inaceptable para uso clínico individual, pero puede ser aceptable en un sistema de vigilancia poblacional donde el objetivo es reducir la brecha de atención, y no tanto el garantizar una cobertura perfecta.

VIII. CONCLUSIONES Y RECOMENDACIONES

Los hallazgos más relevantes para la toma de decisiones en salud pública son:

1. **Los síntomas afectivos son la señal más potente:** sentirse solo con frecuencia y presentar insomnio por preocupación predicen riesgo suicida con mayor fuerza que cualquier otro dominio medido. Las intervenciones que fortalezcan la salud emocional y los vínculos sociales tienen el mayor potencial de impacto.
2. **El consumo de sustancias es el segundo factor modificable clave:** alcohol y drogas aparecen como predictores significativos. Los programas de prevención del uso de sustancias en escuelas deben ser parte integral de cualquier estrategia de salud mental.
3. **El IMC no es predecible desde encuestas conductuales:** invertir en programas de nutrición basados exclusivamente en autorreporte de comportamientos sería insuficiente, se requieren mediciones directas de peso y talla.
4. **La actualización de datos es la prioridad:** ningún modelo entrenado sobre datos de 2013 puede sustituir

una nueva ronda de encuesta GSHS. Se recomienda al Ministerio de Salud gestionar con la OMS la realización de un nuevo GSHS para El Salvador.

5. **El sistema propuesto puede operar como herramienta de vigilancia epidemiológica:** el clasificador de salud mental (AUC-ROC = 0.808, recall = 0.623) tiene capacidad suficiente para priorizar grupos de riesgo a escala departamental si se integra, por ejemplo, en una encuesta escolar anual.

REFERENCIAS

- [1] World Health Organization, “El Salvador — Global School-based Student Health Survey 2013,” WHO NCD Microdata Repository. [Online]. Available: <https://extranet.who.int/ncdsmicrodata/index.php/catalog/97>. [Accessed: Jun. 2026].
- [2] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [3] G. Lemaître, F. Nogueira, and C. K. Aridas, “Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning,” *Journal of Machine Learning Research*, vol. 18, no. 17, pp. 1–5, 2017.
- [4] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [5] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [6] IEEE, “IEEE Standard for Floating-Point Arithmetic,” *IEEE Std 754-2019*, pp. 1–84, 2019.